

التعلم العميق Deep Learning

○ الدرس الأول :	التعلم العميق و الشبكات العصبية
• الأسبوع الأول :	مقدمة للتعلم العميق
• الأسبوع الثاني :	أساسيات الشبكات العصبية
• الأسبوع الثالث :	الشبكات العصبية المجوفة
• الأسبوع الرابع :	الشبكات العصبية العميقة
○ الدرس الثاني :	تطوير الشبكات العميقة : المعاملات العليا
• الأسبوع الأول :	السمات العملية للتعلم العميق
• الأسبوع الثاني :	الحصول علي القيم المثالية
• الأسبوع الثالث :	ضبط قيم الشبكات العميقة
○ الدرس الثالث :	هيكلية مشاريع الـ ML
• الأسبوع الأول :	استراتيجيات الـ ML - 1
• الأسبوع الثاني :	استراتيجيات الـ ML - 2
○ الدرس الرابع :	الشبكات العصبية الملتفة CNN
• الأسبوع الأول :	أساسيات الشبكات العصبية الملتفة
• الأسبوع الثاني :	حالات عملية من الشبكات العصبية الملتفة
• الأسبوع الثالث :	التعرف علي الأشياء
• الأسبوع الرابع :	التعرف علي الوجه
○ الدرس الخامس :	الشبكات العصبية المتكررة RNN
• الأسبوع الأول :	مفهوم الشبكات العصبية المتكررة
• الأسبوع الثاني :	المعالجة اللغوية الطبيعية NLP
• الأسبوع الثالث :	نماذج التتابع

درس 1: التعليم العميق و الشبكات العصبية


الأسبوع الثالث : الشبكات العصبية المجوفة

عقب الانتهاء من هذا الاسبوع , ستكون قادرا علي :


- فهم معنى الوحدات والطبقات الخفية في الشبكات العصبية
- تطبيق دوال متعددة في الشبكات العصبية
- بناء شبكة عصبية أمامية و خلفية
- ستكون ماهرا مع مصطلحات و مفاهيم الشبكات العصبية
- بناء و تدريب شبكة عصبية بطبقة خفية

* * * * *


كمراجعة سريعة , بالفعل عرفنا ان اي شبكة عصبية يكون ليها مداخل معينة إكسات , ويكون ليها مخرج واي هات اللي بجيب منه a



و ان المداخل بتكون اكسات و زائد دبليو (الثبتات) و b اللي هي ثيتا 0 , و بجيب z منها , ومنها a و منها معادلة الخطا




وهتكون الشبكة العصبية كالتالي :




مداخل اكسات للوحدات الاصلية , و هنشير لرقم الطبقة برقم اعلي superscript بين قوسين مربعين [1] اما الرقم اللي بيتعمل فوق برضه و بيكون لرقم العينة فيكون بين قوسين دائريين (1)

وبالتالي هيتم من الطبقة الاولى استخدام اكس 1 و دبليو 1 و بي 1 , لحساب a_1 , z_1 , وبعدها يتم استخدام a_1 اللي هي كانها اكس 2 , مضاف اليها دبليو 2 و بي 2 , لحساب a_2 , z_2 و منها معادلة التكلفة


هنتكلم عن الشبكة العصبية بطبقة خفية اللي هي كدة :



و الطبقة الاولى بتسمى طبقة المدخلات , والتانية الخفية , والتالته اسمها طبقة المخرج



و ممكن نسمي ان المدخلات الاكسات باسم a_0 , و ان الطبقة الخفية اسمها $a[1]$ مع مراعاة ان اقواسها مربعة عشان تشير للطبقة , وبالنسبة لكل وحدة فيهم هيكون ليها رقم فوق 1 مربع , مع رقم تحت يشير لرقم الوحدة فيهم , زي كدة



بحيث ان الـ a هي عبارة عن مصفوفة عمود واحد , وفيها صفوف بعدد وحدات الطبقة المعنية

$$a^{[1]} = \begin{bmatrix} a_1^{[1]} \\ a_2^{[1]} \\ \vdots \\ a_4^{[1]} \end{bmatrix}$$

و اخيرا الـ a_3 هي المخرج يعني يساوي واي هات

ولاحظ ان الشبكة ديه اسمها شبكة بطبقتين , لان دايما طبقة المدخلات لا يتم عدها , وببساطة عليها رقم صفر , عشان كدة عندها a_0 و الطبقة الخفية a_1

ماذا عن المعاملات (الثبتات او رموز w, b) ؟


الطبقة الخفية (الاولي) اللي عندها $a1$ تحتاج $w1.b1$, ولاحظ ان $w1$ هي مصفوفة عدد صفوفها هي عدد وحدات الطبقة الخفية , وعدد عواميدها هي عدد مدخلات الاكسات , يعني هنا هتكون 4 في 3 , لان فيه 4 وحدات في الخفية و 3 اكسات

اما b فبتكون مصفوفة عدد صفوفها كمان عدد وحدات الطبقة الخفية و عمود واحد دائما , يعني هنا 4 في 1


* * * * *

تتبع حساب معادلة الشبكة العصبية


في كل خلية من الشبكة باحسب حاجتين , قيمة الـ z بالمعادلة المعروفة , وقيمة a بسيجمويد الـ z



ولو قلنا ان ديه هي الشبكة عندنا :




فهنمस्क اول جزء منها , اللي هو الاسم اللي طالعة من الطبقة 0 (المدخلات) للطبقة الاولى (الخفية) اللي هي ديه




هناقي في الخلية فوق , بيتحسب نفس الحاجتين , الـ a , z , وهيكونو كدة

notation




اول حاجة اللي هي z و مكتوب 1 فوق و تحت , الفوق (superscript) عشان يحدد انه الطبقة الاولى , واللي تحت (subscript) عشان يحدد انه الخلية الاولى ونفس الكلام علي w , b المستخدمة فيها كمان في a في المعادلة الثانية , ففوق دايما الطبقة و تحت الخلية

ونفس الفكرة في الخلية الثانية هنا



متنصاش ان فوق لسة رقم 1 لاننا في نفس الطبقة , بينما تحت اتغيرت الارقام لـ 2 عشان ديه الخلية الثانية

وبالتالي ممكن نعمم الكلام علي باقي الخلايا كدة :



$$z_1^{[1]} = w_1^{[1]T} x + b_1^{[1]}, a_1^{[1]} = \sigma(z_1^{[1]})$$

$$z_2^{[1]} = w_2^{[1]T} x + b_2^{[1]}, a_2^{[1]} = \sigma(z_2^{[1]})$$

$$z_3^{[1]} = w_3^{[1]T} x + b_3^{[1]}, a_3^{[1]} = \sigma(z_3^{[1]})$$

$$z_4^{[1]} = w_4^{[1]T} x + b_4^{[1]}, a_4^{[1]} = \sigma(z_4^{[1]})$$

اول حاجة هنعملها اننا هنجمع قيم w مع بعضها في صفوف w كبيرة اللي هتكون كدة

$$\begin{bmatrix} w_1^{(1,1)} \\ w_2^{(1,2)} \\ w_3^{(1,3)} \\ w_4^{(1,4)} \end{bmatrix}$$

(4,3)

واللي هتكون عدد صفوفها هو عدد الخلايا في الطبقة الخفية و عدد عواميدها هو عدد المدخلات في الطبقة 0

بعدها هنجمع اكسات مع بعض في مصفوفة x كبيرة

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$$

ولو ضربنا المصفوفتين في بعض هتعملنا مصفوفة 4 في 1 هتكون كدة

$$\begin{aligned} &\rightarrow \omega_1^T x \\ &\rightarrow \omega_2^T x \\ &\rightarrow \omega_3^T x \\ &\rightarrow \omega_4^T x \end{aligned}$$

ولو جمعنا البيئات مع بعض في مصفوفة B واللي هتكون كمان 4 في 1 زي كدة

$$\begin{bmatrix} b_1 \\ b_2 \\ b_3 \\ b_4 \end{bmatrix}$$

ولو جمعناها علي حاصل ضرب W في X هتكون كدة


$$\begin{bmatrix} \omega_1^T \\ \omega_2^T \\ \omega_3^T \\ \omega_4^T \end{bmatrix}_{(4,3)} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} + \begin{bmatrix} b_1 \\ b_2 \\ b_3 \\ b_4 \end{bmatrix} = \begin{bmatrix} \omega_1^T x + b_1 \\ \omega_2^T x + b_2 \\ \omega_3^T x + b_3 \\ \omega_4^T x + b_4 \end{bmatrix} = \begin{bmatrix} z_1 \\ z_2 \\ z_3 \\ z_4 \end{bmatrix}$$

وهي اللي تمثل قيمة Z اللي هي مجموع قيم Z مع بعض

و اخيرا ممكن نجمع قيم a في مصفوفة A عشان تكون هي سيجمويد قيم Z

$$\rightarrow a^{(2)} = \begin{bmatrix} a_1^{(2)} \\ \vdots \\ a_4^{(2)} \end{bmatrix} = \sigma(z^{(2)})$$

واخيرا في الطبقة الاخيرة (المخرج) ستكون معادلة شبيهة



Given input x:

$$\rightarrow z^{[1]} = W^{[1]} a^{(0)} + b^{[1]}$$

(4,1) (4,3) (3,1) (4,1)

$$\rightarrow a^{[1]} = \sigma(z^{[1]})$$

(4,1) (4,1)

$$\rightarrow z^{[2]} = W^{[2]} a^{[1]} + b^{[2]}$$

(1,1) (1,4) (4,1) (1,1)

$$\rightarrow a^{[2]} = \sigma(z^{[2]})$$

(1,1) (1,1)

هتلاحظ ان $Z[2]$ (رقم 2 لانها في الطبقة الثانية) هتساوي ضرب $W[2]$ (ثباتات الطبقة الثانية) في $a[1]$ (مخرج الطبقة الاولى اللي هو يعتبر مدخل الطبقة الثانية كانه بديل لإكس), زائد $b[2]$ (ثباتا صفر الطبقة الثانية)


مصفوفة $Z[2]$ هتكون 1 في 1 لانها رقم لوحده, $W[2]$ هتكون 1 في 4, لان عدد خلايا الطبقة بتاعتها 1, وعدد مدخلاتها (هي نفس مخرجات الطبقة الاولى) 4, مصفوفة الـ $a[1]$ هي 1 في 4 لانها اربع قيم, والـ $b[2]$ قيمة واحدة

فحاصل الضرب هيبكون قيمة واحدة, ووبالتالي السيجمويدها هيبكون قيمة اللي هو a_2

اتعرفنا من شوية علي ازاى نتعامل مع لعينة واحدة , فماذا لما بيكون عندي عدد كبير من العينات ؟

الفكرة ان هيتم تطبيق نفس اللي تم مع عينة واحدة , لكن مع وضعه في مصفوفات اكبر لاكمال العملية


في العملية اللي فاتت , من قيم اكسات تم حساب قيمة $a[1]$ و $z[1]$ و $a[2]$ و $z[2]$, ومتنساش ان الـ $a[2]$ هي الناتج النهائي يعني واي هات



$$\begin{cases} z^{[1]} = W^{[1]}x + b^{[1]} \\ a^{[1]} = \sigma(z^{[1]}) \\ z^{[2]} = W^{[2]}a^{[1]} + b^{[2]} \\ a^{[2]} = \sigma(z^{[2]}) \end{cases}$$

فهتعيد نفس الخطوات , لكن لعينة تانية , يعني كل اللي فات كان لـ $x(1)$, هنبداً نعمله لـ $x(2)$, $x(3)$, $x(m)$, عشان يجيلنا واي هات 1 و 2 و 3

متنساش ان القوس الدائري () يشير لرقم العينة , والقوس المربع [] يشير لرقم الطبقة



هتلاقى ان واي هات 1 مثلا اسمها $a[2](1)$ و ده معناها انها a للطبقة الثانية (يعني واي هات) و هي للعنصر 1

نفس الفكرة لـ $a[2](i)$, معناها الواي هات او المخرج للعنصر i

وبفرض اننا هنعملها بفور (من غير broadcasting) هيكون الكود كدة

for $i = 1$ to m :

$$z^{[1](i)} = W^{[1]}x^{(i)} + b^{[1]}$$

$$a^{[1](i)} = \sigma(z^{[1](i)})$$

$$z^{[2](i)} = W^{[2]}a^{[1](i)} + b^{[2]}$$

$$a^{[2](i)} = \sigma(z^{[2](i)})$$

فهلقول ان X الكبيرة هي مصفوفة عواميدها بعدد العينات , وصفوفها بعدد الإكسات زي كدة

$$X = \begin{bmatrix} x_{(1)} & x_{(2)} & \dots & x_{(n)} \\ \vdots & \vdots & & \vdots \\ x_{(n_x, m)} & & & \end{bmatrix}$$

وان الـ $Z[1]$ نفس الفكرة , كل عمود فيها هو قيمة $z[1]$ لكل عينة فيها , زي كدة

$$Z^{[1]} = \begin{bmatrix} 1 & 1 & \dots & 1 \\ z^{1} & z^{[1](2)} & \dots & z^{[1](m)} \\ 1 & 1 & \dots & 1 \end{bmatrix}$$

وإن الـ $A[1]$ سيكون فيها قيم $a[1]$ لكل عينة في كل عمود , زي كدة

$$A^{[1]} = \begin{bmatrix} \bullet & \bullet & \dots & \bullet \\ \bullet & \bullet & \dots & \bullet \\ a & a & \dots & a \\ 1 & 1 & \dots & 1 \end{bmatrix}$$

وخذ بالك ان الـ $a[1]$ نفسها هي قيم a المتعددة للطبقة الاولى (الخفية) , وكل a فيهم تعبر عن خلية من الخلايا , فالنقطة اللي فوق علي الشمال في المصفوفة تمثل قيمة a للخلية الاولى للعينة الاولى , واللي تحتها قيمة a للخلية الثانية للعينة الاولى , بينما لو دخلت علي اليمين هتكون قيمة a للخلية الاولى للعينة الثانية و هكذا

ساعاتها هتكون المعادلات كدة :

$$\begin{aligned} z^{[1]} &= W^{[1]} X + b^{[1]} \\ \Rightarrow A^{[1]} &= c(z^{[1]}) \\ \Rightarrow z^{[2]} &= W^{[2]} A^{[1]} + b^{[2]} \\ \Rightarrow A^{[2]} &= c(z^{[2]}) \end{aligned}$$

* * * * *

الدالة المستخدمة لـ a

في كل شغلنا كنا نتعامل مع الدالة المستخدمة لـ a علي انها السيجمويد

$$a^{[1]} = \sigma(z^{[1]})$$

لكن ده ميمنعش ان فيه دوال تانية مستخدمة , منها الدالة المسماة دالة الـ G و اللي بتستخدم دالة التانش \tanh


$$g(z) = \tanh(z)$$

واللي بتساوي رياضيا :


$$\frac{e^z - e^{-z}}{e^z + e^{-z}}$$

الي هي اكسبونينشيل زي , ناقس اكسبو ناقص زي , علي نفس القيمتين مجموعين مش مطروحين

وبيكون شكلها كدة :




بينما السيجمويد كدة



فكانها نسخة منها , لكن معمولة shift يعني بدل ما تبدأ من 0 لـ 1 (المدي 1) في السيجمويد , بتبدأ من سالب 1 الي 1 (المدي 2) و فرق المدي ده مهم في حاجة . .



اني غالبا في كل طبقات الـ NN باستخدام دالة الـ G اللي هي تانش , لان وجود الصفر كمتوسط بيرحني جدا في الحسابات , و بيكون احسن ما استخدم السيجمويد , ويكون الـ 0.5 هو المتوسط

باستثناء اخبر طبقة اللي بتجيب النتيجة واي هات , ساعتها هستخدم السيجمويد , لاني عايز المخرج يكون يا 1 يا صفر يا رقم بينهم , مش عايز اشوف اي رقم سالب هيعمل لغبطة



فالصورة باين فيها ان كل الدوال الداخلية تانش , بينما الدالة الاخيرة سيجمويد


لكن أحد العيوب الخطيرة في كلا من الدالتين السجمويد و التانش , ان لو قيمة z كبيرة قوي (علي اليمين) او صغيرة قوي (علي الشمال) ساعتها الاشتقاق بيكون قيمت صغيرة جدا , وده اللي هتلاحظه ان ميل الخط اليمين و الشمال في كلا من الرسمين شبه افقي



وده مشكلته انه بيخلي الانحدار التدريجي بطئ جدا , لانه قائم علي طرح قيمة الاشتقاق مضروبة في الفا من قيمة ثباتات , فهايخذ وقت كثير علي ما يوصل للقيمة المثلي

ويكون البديل المناسب استخدام ReLU وهو اختصار Rectified Linear Unit

واللي بتعمل الشكل ده



الدالة بتاعتها هي : $a = \max(0, z)$

معناها ان اي قيمة لـ z بالسالب يتم استخدام صفر بديل لها , اما لو كانت موجبة فتستخدم

وديه ميزتها ان لو قيمة z سالب فهيكون الاشتقاق بصفر بالفعل , اما لو موجب فهيكون قيمة واضحة سهل التعامل معاها

بس فيه اصدار احسن من الـ ReLU وهو ما يسمى الـ leaky , واللي الجزء الموجب فيها هو نفسه , بس الجزء السالب منحدر انحدار بسيط , عشان يظل الاشتقاق قيمة موجبة خفيفة جدا

نوع المعادلة المستخدمة في الأكتيفاشن a

الاكتيفاشن هي عمل المعادلة a من قيمة z والتي كانت بتتعمل بالسيجمويد او التانش

السؤال بقي , ليه متتعلمش خطية linear ؟ ؟
عشان نعرف ليه المفروض متتعلمش خطية , تعالى نفترض انها خطية و نشوف النتيجة هتكون ايه

المعادلة الخطية بتكون

$$Y = X$$

$$a = z$$

فهتكون هنا

بالشكل ده بدل دالة سيجمويد او تانش :

$$a^{[1]} = g^{[1]}(z^{[1]})$$

وقتها a هتساوي z يعني هتساوي حاصل ضرب دبليو في اكس زائد بي

$$a^{[1]} = z^{[1]} = w^{[1]}x + b^{[1]}$$

ونفس الفكرة في a2

$$a^{[2]} = z^{[2]} = w^{[2]}a^{[1]} + b^{[2]}$$

ساعتها هنعوض بدل a_1 بقيمتها من فوق ونختصرها :

$$\begin{aligned} a^{[2]} &= w^{[2]} \underbrace{(w^{[1]}x + b^{[1]})}_{a^{[1]}} + b^{[2]} \\ &= \underbrace{(w^{[2]} w^{[1]})}_{w'} x + \underbrace{(w^{[2]} b^{[1]} + b^{[2]})}_{b'} \\ &= \underbrace{w'x + b'}_{\end{aligned}$$

يعني بقت معادلة خطية برضه
وديه بتعملنا مشاكل كتير , ومش بتحيب نتائج دقيقة

ده السبب اللي لازم نستخدم احدي معادلات سيجمويد او تانش في الـ NN باستثناء لو هاعمل توقع regression و حتى ده يستحسن مستخدمش خطي برضه

* * * * *

طيب تعالى نتكلم عن اشتقاق السيجمويد :
دالة السيجمويد اللي هي ديه :

$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

لو جيت اجيب الميل بتاعها يعني اعمل لها اشتقاق و هتكون كدة


$$\frac{1}{1 + e^{-z}} \left(1 - \frac{1}{1 + e^{-z}} \right)$$

يعني ممكن نقول

$$\frac{g(z) (1 - g(z))}{a (1 - a)}$$

ولأننا بنطلق علي g حرف a فممكن نقول انها كدة

ولو بصينا في الرسم هنفهم الارقام :



هتلاقى ان فيه حالة قيمة z رقم كبير , مثلا 10 , هيكون الاكسبونينشيل برقم صغير جدا , يعني قيمة السيجمويد هتكون بواحد , وبالتالي لما اعمل اشتقاق هيكون 1 في 1 ناقص 1 , يعني 1 في 0 يعني صفر , وبالتالي الميل بصفر وفعلا لان الخط شبه افقي

ولو اخترت رقم صغير جدا , مثلا سالب 10 , فالاكسبونينشيل هيكون برقم كبير جدا , فالسيجمويد هيكون بصفر , يعني الاشتقاق هيكون صفر في 1 ناقص 0 , يعني كمان صفر , و فعلا الخط افقي

بينما لما يكون الرقم صفر , هيكون الاكسبونينشيل بواحد , يعني السيجمويد بنص , فالاشتقاق هيكون نص في نص يعني ربع , وده منطقي

طيب ماذا عن دالة التانש . البديلة للسيجمويد ؟

دالة التانש اصلا تساوي

$$\frac{e^z - e^{-z}}{e^z + e^{-z}}$$

ولو جيت تعملها اشتقاق هتلاقيها بقت 1 ناقص نفس الدالة تربيع , يعني كدة

$$1 - (\tanh(z))^2$$

ولو قلنا في حالة z تساوي رقم كبير و ليكن 10 , فاكسبو الـ 10 يساوي رقم كبير جدا , ناقص اكسبو سالب 10 يعني تقريبا صفر , علي نفس الرقم زائد صفر هيكون بيساوي 1


الاشتقاق هيكون 1 ناقص 1 تربيع يعني صفر , عشان كدة الخط شبه افقي

بينما لو كان الرقم صغير جدا وليكن سالب 10 , فاكسبو سالب 10 برقم تقريبا صفر , سالب اكسبو سالب سالب 10 يعني سالب رقم كبير جدا , , مقسوم علي صفر زائد رقم كبير جدا , يعني في النهاية سالب 1

في الاشتقاق هربعه و اطرح منه واحد هيكون كمان صفر

اما في حالة z تساوي صفر , فاكسبو الصفر او سالب صفر بواحد , ففوق هيكون 1 ناقص 1 , علي $1 + 1$, هيكون بصفر , الاشتقاق هيكون بواحد , وده سليم

وفي حالة دالة الـ ReLU بيكون الموضوع اسهل شوية




ReLU

$$g(z) = \max(0, z)$$

$$g'(z) = \begin{cases} 0 & \text{if } z < 0 \\ 1 & \text{if } z \geq 0 \end{cases}$$

ببساطة سيكون الاشتقاق بصفر في حالة الـ z سالبة , وبواحد في حالة الـ z موجبة , وده لانها دالة خطية من الناحية اليمني وفي حالة الـ **leaky** سيكون نفس الموضوع باستثناء ان في السالب سيكون المعامل اللي تم اختياره لانحناء الجزء السالب



Leaky ReLU

$$g(z) = \max(0.01z, z)$$

$$g'(z) = \begin{cases} 0.01 & \text{if } z < 0 \\ 1 & \text{if } z > 0 \end{cases}$$

*_**

الانحدار التدريجي للـ NN

كمراجعة سريعة لخطوات حساب الانحدار التدريجي للـ NN :

أولا هنقول , ان عندنا عدد وحدات n_0 وهو عدد اكسات المدخل , و n_1 و هو عدد وحدات الطبقة الخفية , و n_2 وهو عدد وحدات الطبقة الثانية اللي هي المخرج اللي هتكون 1 , وده بفرض ان عندنا طبقة خفية واحدة

$$n_x = n^{[0]}, \quad n^{[1]}, \quad \underline{n^{[2]} = 1}$$

وبالنسبة للمصفوفات هتكون كدة

$$\text{Parameters: } \begin{matrix} w^{[0,1]} & b^{[0,1]} \\ w^{[1,2]} & b^{[1,2]} \end{matrix}$$

يعني مصفوفة w_1 (وهي ثباتات من المدخلات للطبقة الخفية) هتكون ابعادها n_1 في n_0 يعني صفوفها هو عدد وحدات الطبقة الخفية , وعواميدها هو عدد مدخلات الاكس

بالنسبة لـ b_1 هتكون n_1 في 1 , يعني صفوفها عدد وحدات الطبقة الخفية في عمود واحد

اما مصفوفة w_2 (وهي ثباتات من الطبقة الخفية للمخرج) هتكون ابعادها n_2 في n_1 يعني صفوفها هو عدد وحدات الطبقة الخارجية (يعني 1), وعواميدها هو عدد وحدات الطبقة الخفية

بالنسبة لـ b_2 ستكون n_2 في 1 , يعني صفوفها عدد وحدات الطبقة الخارجية (يعني 1) في عمود واحد , يعني رقم واحد

بعدها نحتاج دالة الخطا cost function والتي ستكون

$$\text{Cost function: } J(w^{(2)}, b^{(2)}, \underbrace{w^{(2)}}_{\uparrow}, \underbrace{b^{(2)}}_{\uparrow}) = \frac{1}{n} \sum_{i=1}^n \ell(\hat{y}_i, y_i)$$

$\uparrow \quad \quad \quad \uparrow$
 $\alpha \quad \quad \quad \alpha$

والتي بتحسب نسبة الفروق بين قيمة واي المتوقعة و واي الحقيقية

بعدها نحتاج الانحدار التدريجي , يعني اشتقاقات الـ w, b

$$\underline{\frac{\partial J}{\partial w^{(2)}}} = \frac{\partial J}{\partial w^{(2)}}, \quad \underline{\frac{\partial J}{\partial b^{(2)}}} = \frac{\partial J}{\partial b^{(2)}}$$

بعدها نعمل تعديل لقيم w و b اننا نطرح منها قيمة الاشتقاق مضروب في الفا

$$w^{(2)} := w^{(2)} - \alpha \frac{\partial J}{\partial w^{(2)}} \\ b^{(2)} := b^{(2)} - \alpha \frac{\partial J}{\partial b^{(2)}}$$

وبالنسبة للحساب الامامي forward propagation

Forward propagation:

$$z^{[1]} = w^{[1]}x + b^{[1]}$$

$$A^{[1]} = g^{[1]}(z^{[1]}) \leftarrow$$

$$z^{[2]} = w^{[2]}A^{[1]} + b^{[2]}$$

$$A^{[2]} = g^{[2]}(z^{[2]}) = \sigma(z^{[2]})$$

هتكون نفس المعادلات اللي اخدناها سابقا

وبالنسبة للحساب العكسي back propagation

Back propagation:

$$dz^{[2]} = A^{[2]} - Y \leftarrow$$

$$Y = [y^{(1)} \ y^{(2)} \ \dots \ y^{(n)}]$$

$$dW^{[2]} = \frac{1}{n} dz^{[2]} A^{[1]T}$$

$$(n, 1) \leftarrow$$

$$\downarrow (n^{[2]}, 1) \leftarrow$$

$$db^{[2]} = \frac{1}{n} \text{np.sum}(dz^{[2]}, \text{axis}=1, \text{keepdims}=\text{True})$$

$$dz^{[1]} = \underbrace{W^{[2]T}}_{(n^{[2]}, m)} dz^{[2]} \underset{\substack{\uparrow \text{element-wise} \\ \text{product}}}{*} \underbrace{g^{[2]'}(z^{[1]})}_{(n^{[1]}, m)} \quad (n^{[1]}, m)$$

$$dW^{[1]} = \frac{1}{n} dz^{[1]} X^T$$

$$db^{[1]} = \frac{1}{n} \text{np.sum}(dz^{[1]}, \text{axis}=1, \text{keepdims}=\text{True})$$


$(n^{[1]}, 1)$
 $(n^{[1]}, 1)$

هتكون ديه المعادلات , مع عمل بعض الاكواد الخاصة بها في بايثون

اخر حاجة هنا هي ماذا عن القيم المفترضة للثيتات , اللي هي w , b

في التوقع كنا عادي ممكن ابدا الثيتات بصفر , وكانت المسئلة هتعدل القيم لما توصل للقيم السليمة , بس هنا مش هينفع نخلي w باصفار , مع ان ممكن b تكون اصفار

فمثلا نبص هنا



لو عملت w باصفار , ساعتها مصفوفة الـ w و الـ b هتكون كدة

$$w^{(1)} = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix} \quad b^{(1)} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

وديه هتخلي القيمتين الـ a_1 , a_2 اللي في الطبقة الخفية هيعملو نفس القيمة , لان كلا منهما هيتحسبو من الـ z بمعادلة

$$z^{[1](i)} = W^{[1]}x^{(i)} + b^{[1]}$$

$$a^{[1](i)} = \sigma(z^{[1](i)})$$

و ده هيجعل قيمتي $a1$, $a2$ متساويتين

بعده لما اجي اجيب $dz1$, $dz2$ هيكونو زي بعض , وبالتالي $dw1$, $dw2$

و هنا لما اجي اعمل update لقيمة w بالمعادلة

$$w^{\tau+1} = w^{\tau} - \alpha \Delta w$$

مش هتتغير ابدأ , وهتفضل بنفس قيمتها , وده مش هيحل المسألة


ساعتها هيكون الحل ان يتم الاستعانة بأرقام عشوائية باستخدام دالة

وبعدها اكتب ابعاد المصفوفة المطلوبة

فهنا مثلاً :

`np.random.rand`

$w^{[1]} = \text{np.random.randn}(2,2) \times \frac{0.01}{100?} \rightarrow$
 $b^{[1]} = \text{np.zeros}(2,1)$
 $w^{[2]} = \dots$
 $b^{[2]} = 0$



عمانا w_2 مصفوفة عشوائية 2 في 2 ، و b مصفوفة 2 في 1 ، و w_2 هتكون 1 في 2 ، و b_2 1 في 1

هتلاحظ ان اولا قيم b_1, b_2 باصفار , وديه عادي مفيش مشاكل , طالما الدبليو ليها قيم

كمان هتشوف ان تم ضرب 0.01 في قيم دبلو , وده عشان اخلي قيم الثيتات صغيرة جدا , عشان اخلي قيم z صغيرة وبالتالي متدخلش في مشكلة الارقام الكبيرة في السيجمويد او التانش , واللى فيها الاشتقاق بيكون قليل جدا , فهتكون شديدة البطئ في الحل

و اختيار رقم 0.01 بالتحديد هو مناسب للشبكات المجوفة Shallow NN و اللي قصدي بيها ان فيها طبقة خفية واحدة , لكن لو عندي شبكات عميقة فيها طبقات كتير ساعتها هيتم اختيار رقم مختلف , وهنشوف قدام نختاره ازاى

* * * * *

نهاية الاسبوع الثالث